



INFO-4185 Grundlagen des Maschinellen Lernens

Andreas Schilling

Inhalt

Heute:

- Einführung
- Anwendungen
- Techniken

Was ist Maschinelles Lernen?

Lernen: Verhaltensanpassung durch

- Erwerb von Wissen und Fähigkeiten
- Das Wesentliche, die Essenz aus (möglichst wenigen) Beispieldaten extrahieren

Die Fähigkeit, aus Erfahrung zu Lernen, ist wesentlicher Teil jedes intelligenten Systems

Die Beschäftigung mit Maschinenlernen hilft, auch das menschliche Lernen besser zu verstehen

Was ist Machine Learning?

28.04.2017

Voraussetzung:

- Verschiedene Situationen sind ähnlich

Frage:

- Was ist Ähnlichkeit

Anwendungen:

28.04.2017

- Klassifizierung
- Regression
- Bestimmung von Parametern aus Daten
- Prädiktion
- Dimensionalitätsreduktion (Beseitigung von Redundanz, Extraktion von Wesentlichem)
- Clusteranalyse
- Modellierung der Datenentstehung
- Detektion von Ausreißern

auf der Grundlage von (Beispiel-)Daten

Klassifizierung

28.04.2017

Automatische Unterscheidung
zw. Lachs und Seebarsch




FIGURE 1.1. The objects to be classified are first sensed by a transducer (camera), whose signals are preprocessed. Next the features are extracted and finally the classification is emitted, here either "salmon" or "sea bass". Although the information flow is often chosen to be from the source to the classifier, some systems employ information flow in which earlier levels of processing can be altered based on the tentative or preliminary response in later levels (gray arrows). Yet others combine two or more stages into a unified step, such as simultaneous segmentation and feature extraction. From: Richard O. Duda, Peter E. Hart, and David G. Stork, *Pattern Classification*. Copyright © 2001 by John Wiley & Sons, Inc.

Klassifizierung

28.04.2017


Gesichtsdetektion




Diplomarbeit W Kienzle 2003

Regression – Bestimmung von Parametern aus Daten

28.04.2017




Experiments: Pose & Illumination Estimation



Prädiktion

28.04.2017

Börsenvorhersagen



Expert Prediction, Symbolic Learning, and Neural Networks: An Experiment on Greyhound Racing

H. Chao, J. P. Bontis, L. Shi, S. Sridharan, C. Somaratne, D. Zeng

Conclusion

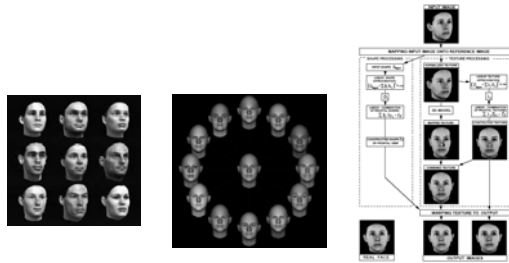
In terms of prediction accuracy and execution speed, both the backpropagation network and the 2/2/1 performed better than human experts. Both algorithms

IEEE EXPERT, 1994

Dimensionalitätsreduktion (Beseitigung von Redundanz)

28.04.2017


Beispiel: Eigenfaces



Clustering


28.04.2017

Beispiel: Segmentierung



Modellierung, Textursynthese, Filter


28.04.2017



Modellierung, Textursynthese, Filter

28.04.2017


Trainingsdaten:



Modellierung, Textursynthese, Filter

28.04.2017

Testdaten:



Modellierung, Textursynthese, Filter

28.04.2017

Trainingsdaten:



Modellierung, Textursynthese, Filter

28.04.2017

Testdaten:




Maschinelles Lernen: Was wird gelernt

28.04.2017

Die Aufgabe:

oft als Funktion darstellbar: $y = f(x, w)$



x, y: Eingabe, Ausgabe; w: Parameter

- Regression: y ist kontinuierlich
- Klassifikation: y ist diskret
- manchmal interessiert auch eine Verteilung $p(y|x)$ (Density Estimation)

Regression: Beispiel

28.04.2017

Voraussage des Körperfettes durch den BMI





Abbildung aus: <http://www.unizh.ch/biostat/Lehre/kor-regr-1jk.pdf>


Klassifikation: Beispiele

28.04.2017

- Zeichenerkennung



- spam filter



Maschinen Lernen: Besser werden!

28.04.2017

Wie wird Erfolg gemessen?

- Maßzahl, z.B. Anteil korrekt klassifizierter Bilder
 - Bei Anwendung auf Trainingsdaten
 - Bei Anwendung auf neue Daten (Generalisierung)

Maschinen Lernen: Womit wird gelernt

28.04.2017

Die Daten:

Supervised Learning:

- Daten mit Kennzeichnung (Ein- und Ausgabe)

Unsupervised Learning:


- Daten ohne Kennzeichnung

Maschinen Lernen: Wie wird gelernt

Lernen ist Optimieren:

Maximierung der Performanz:

- Suche nach bestem Modell
- Suche nach besten Parametern




Grundlagen

Normalverteilung, Kovarianz

Normalverteilung:

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

- innerhalb $\pm\sigma$: ~ 68%
- innerhalb $\pm2\sigma$: ~ 95%
- innerhalb $\pm3\sigma$: ~ 99.7%




Normalverteilung, Kovarianz, Kombination mehrerer Verteilungen

28.04.2017

Zwei Normalverteilungen:

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma_1} e^{-\frac{(x-a)^2}{2\sigma_1^2}}$$

$$g(x) = \frac{1}{\sqrt{2\pi}\sigma_2} e^{-\frac{(x-b)^2}{2\sigma_2^2}}$$




Normalverteilung, Kovarianz, Kombination mehrerer Schätzungen

28.04.2017

Kombination

durch Multiplikation

$$\begin{aligned} h(x) &= f(x)g(x) \\ &= \frac{1}{\sqrt{2\pi}\sigma_1\sigma_2} e^{-\frac{(x-a)^2}{2\sigma_1^2} - \frac{(x-b)^2}{2\sigma_2^2}} \end{aligned}$$




Normalverteilung, Kovarianz, Kombination mehrerer Schätzungen

28.04.2017

Normierung von $h(x)$:

$$\begin{aligned} h_n(x) &= \frac{1}{\sqrt{2\pi}\sigma_3} e^{-\frac{(x-c)^2}{2\sigma_3^2}} \\ c &= \frac{a\sigma_2^2 + b\sigma_1^2}{\sigma_1^2 + \sigma_2^2} \\ \frac{1}{\sigma_3^2} &= \frac{1}{\sigma_1^2} + \frac{1}{\sigma_2^2} \end{aligned}$$




Normalverteilung, Kovarianz, Kombination mehrerer Schätzungen

28.04.2017

2-Dimensional:

$$f(x, y) = \frac{1}{2\pi\sigma_x\sigma_y} e^{-\frac{1}{2}\left(\frac{(x-a)^2}{\sigma_x^2} + \frac{(y-b)^2}{\sigma_y^2}\right)}$$




Normalverteilung, Kovarianz, Kombination mehrerer Schätzungen

28.04.2017

2-Dimensional,
nicht achsenparallel (mit
Hilfe der Kovarianzmatrix
[σ^2]=C):

$$f(\mathbf{x}) = ce^{-\frac{1}{2}\mathbf{x}^T C^{-1} \mathbf{x}}$$



Normalverteilung, Kovarianz, Kombination mehrerer Schätzungen

28.04.2017

Kovarianzmatrix kann berechnet werden als
Erwartungswert der quadrierten Abweichungen vom
wahrscheinlichsten Wert.

- Inneres Produkt (Skalarprodukt): $\mathbf{y}^T \mathbf{x}$

$$\mathbf{y}^T \mathbf{x} = \begin{pmatrix} y_1 & y_2 & y_3 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = x_1 y_1 + x_2 y_2 + x_3 y_3$$

- Äußeres Produkt: $\mathbf{y} \mathbf{x}^T$

$$\mathbf{y} \mathbf{x}^T = \begin{pmatrix} y_1 \\ y_2 \\ y_3 \end{pmatrix} \begin{pmatrix} x_1 & x_2 & x_3 \end{pmatrix} = \begin{pmatrix} y_1 x_1 & y_1 x_2 & y_1 x_3 \\ y_2 x_1 & y_2 x_2 & y_2 x_3 \\ y_3 x_1 & y_3 x_2 & y_3 x_3 \end{pmatrix}$$

Kovarianzmatrix

$$\mathbf{d}_i = \begin{pmatrix} d_{x,i} \\ d_{y,i} \\ d_{z,i} \end{pmatrix} = \mathbf{x}_i - \bar{\mathbf{x}}_i = \begin{pmatrix} x_i \\ y_i \\ z_i \end{pmatrix} - \begin{pmatrix} \bar{x}_i \\ \bar{y}_i \\ \bar{z}_i \end{pmatrix}$$

$$\mathbf{C} = E[\mathbf{d}\mathbf{d}^T] = \frac{1}{n} \sum_{i=1}^n \begin{bmatrix} d_{x,i}^2 & d_{x,i}d_{y,i} & d_{x,i}d_{z,i} \\ d_{x,i}d_{y,i} & d_{y,i}^2 & d_{y,i}d_{z,i} \\ d_{x,i}d_{z,i} & d_{y,i}d_{z,i} & d_{z,i}^2 \end{bmatrix}$$

Übungen / Praktikum Bewertung und Anrechnung

Zusammenhängende Lehrveranstaltungen:

- Vorlesung + Übungen 2-stündig (6 LP)
- Praktikum im Wintersemester
4-stündig (INFO-4162) für Master
- 6 LP Praktische Informatik

Benotung für BSc/MSc

- Vorlesung: Klausur am 28. Juli (Voraussetzung: Übungen)
- Übungen: Bonus für Klausur (max. 20%).

Kriterien für Übungen:

- alle Übungsblätter bearbeitet
- mindestens 50% der Punkte

Übungen



Tobias Lang
Raum C411
Tel. 78968
t.lang@uni-tuebingen.de



Mathias Schickel
Raum C411
Tel. 78968
msch@fa.uni-tuebingen.de

Ressourcen



28.04.2017

Vorlesungsfolien, Papers usw.

- ILIAS-System
 - Informatik » Visual Computing
 - » INF4185 Grundlagen des Maschinellen Lernens
- Password: evidence17
